

目录

前言

第一部分 上岗前的基本功：最少必要的数学与工具

第一章 计算机基础

- 1.1 本章导读：入职之前，你需要一张地图
- 1.2 Linux 基础与远程开发环境：你的工位在哪
- 1.3 你需要的 Python，不是教科书里那种 Python
- 1.4 Python 环境管理：为什么别人能跑你跑不了
- 1.5 PyTorch：深度学习的第一个工具
- 1.6 数据长什么样：JSON、JSONL 与常见数据格式
- 1.7 Git 生存指南：代码后悔药与协作神器
- 1.8 浮点数常识：计算机是怎么存小数的
- 1.9 显卡与 CUDA 常识：你的算力底座

第二章 入门大模型需要的最少必要数学知识

- 2.1 本章导读：你需要多少数学？
- 2.2 线性代数：为什么大模型眼里一切都是向量？
- 2.3 微积分：模型是怎么知道该往哪儿改的？
- 2.4 概率论：大模型如何处理不确定性？

第三章 你的开源武器库：Hugging Face 生态

- 3.1 Hugging Face：开源模型社区导览
- 3.2 开源模型江湖：常见的开源大模型
- 3.3 三行代码跑通你的第一个模型
- 3.4 Tokenizer 入门：文字是怎么变成数字的
- 3.5 下载下来的模型文件夹里都有什么
- 3.6 怎么在 Hugging Face 上快速判断一个模型能不能用

第二部分 深度学习基础：模型是怎么学会的

第四章 机器到底是怎么学习的？

- 4.1 神经网络的基本零件：权重与偏置
- 4.2 激活函数：为什么光做线性变换不够？

4.3	前向传播：数据从输入到输出走了一条什么路？	
4.4	词怎么变成向量：Embedding 层	
第五章 损失函数与梯度下降		
5.1	损失函数：机器怎么知道自己错得有多离谱？	
5.2	Softmax：从分数到概率分布的桥梁	
5.3	交叉熵：文本生成任务里的损失函数	
5.4	梯度下降：蒙着眼睛下山，怎么走到谷底？	
5.5	学习率：步子迈多大是门学问	
第六章 误差是怎么传回去的？		
6.1	反向传播与链式法则：误差一层层甩锅的机制	
6.2	优化器演进：从 SGD 到 Adam	
6.3	训练中的常见问题：过拟合与正则化	
第七章 Transformer 之前：深度学习走过的路		
7.1	大模型的五个历史时刻	
7.2	CNN：让机器学会看图的第一个真正有效的方案	
7.3	RNN：一个王朝的兴衰	
第三部分 大模型的心脏：彻底解构 Transformer		
第八章 注意力机制：大模型为什么能懂上下文？		
8.1	注意力的直觉：打分与加权平均	
8.2	Q、K、V：注意力分数到底是怎么算出来的？	
8.3	多头注意力：为什么要从不同角度看同一句话？	
第九章 Transformer 全景拆解		
9.1	位置编码：不用 RNN，怎么让模型知道词的先后顺序？	
9.2	残差连接与层归一化	
9.3	前馈网络：Transformer 里的记忆体	
9.4	一层 Transformer 内部的数据流	
第十章 从 Transformer 到大模型：架构选型与输出机制		
10.1	Encoder、Decoder 和掩码机制	
10.2	为什么现在的大模型都选 Decoder only	
10.3	从隐藏向量到下一个词：大模型的最后一步	
10.4	Transformer 全面总结：一个 token 从输入到输出的完整旅程	
第十一章 Transformer 的进化：当模型越来越大、越来越杂		
11.1	MoE：不是所有参数每次都要用	
11.2	万物皆可向量：从 Embedding 思想到 ViT 与 CLIP	
11.3	多模态大模型：图片和文字是怎么融合在一起的	
11.4	AI 绘画与扩散模型	

第四部分 训练与调优：让模型学会按要求工作

第十二章 不改参数也能干活：Prompt Engineering 与上下文学习

- 12.1 模型怎么生成文字：解码策略
- 12.2 Prompt Engineering：别让模型答非所问
- 12.3 结构化输出：怎么让大模型稳定地输出 JSON?

第十三章 大模型的出厂与深造：预训练与指令微调

- 13.1 预训练：读书破万卷，读的到底是什么?
- 13.2 指令微调：怎么把读书人变成打工人?
- 13.3 从零跑通一个指令微调任务

第十四章 高效微调：LoRA 的直觉与实战

- 14.1 LoRA 的核心思想：冻结大矩阵，外挂小矩阵
- 14.2 LoRA 实战：用最精简的代码跑通微调任务

第十五章 分布式训练基础

- 15.1 梯度累积与数据并行
- 15.2 ZeRO：消除多卡之间的冗余
- 15.3 张量并行与流水线并行

第十六章 对齐：怎么让模型知道什么是更好的回答？

- 16.1 为什么需要对齐?
- 16.2 PPO：怎么给模型找一个打分老师?
- 16.3 DPO：抛开奖励模型，直接用偏好数据训练
- 16.4 GRPO：用规则代替人工打分

第五部分 应用与落地：让大模型好用又能打

第十七章 不改模型也能补知识：RAG

- 17.1 RAG 的原理：为什么要先检索再生成
- 17.2 从零搭建一个最小 RAG 系统

第十八章 让大模型学会动手：Agent

- 18.1 从回答问题到完成任务：Agent 的核心循环与 Function Calling 机制
- 18.2 ReAct：让模型边想边做
- 18.3 MCP 与 Skills：给 Agent 装上工具箱和资料库

第十九章 推理加速与成本控制

- 19.1 KV Cache：为什么生成第 100 个词不需要重新算前 99 个词?
- 19.2 模型量化：怎么把大模型塞进小显存
- 19.3 模型蒸馏：让小模型学会大模型
- 19.4 显存估算实战：跑一个模型到底需要多少显存?
- 19.5 模型部署基础：怎么把模型变成一个 API 服务?

第二十章 模型评估：怎么证明模型真的变好了？

- 20.1 分类任务的评估：准确率、精确率、召回率、F1
- 20.2 自动评估指标：困惑度、ROUGE、BLEU 和它们的局限
- 20.3 Benchmark 与排行榜：分数到底能不能信
- 20.4 人工评估与 LLM Judge

第六部分 泥潭求生：数据工程的脏活累活

第二十一章 算法工程师的数据全景

- 21.1 算法工程师的日常真相：大部分时间都在和数据打交道
- 21.2 大模型需要什么数据：SFT、偏好、评测与 RAG 知识库
- 21.3 高质量数据从哪来：开源、内部、采购与合作
- 21.4 合成数据：用大模型造数据喂大模型
- 21.5 数据安全和合规：算法工程师必须知道的红线
- 21.6 拿到数据的第一眼：先自己看一遍
- 21.7 数据配比：不同类型的数据该怎么混？

第二十二章 数据标注的全流程：从构造到质检

- 22.1 指令微调数据的标注：怎么定义好回答？
- 22.2 偏好数据的标注：怎么让标注员分出更好和更差？
- 22.3 质检防线：说明书、抽检机制与一致性检验

第二十三章 数据迭代与飞轮

- 23.1 从 bad case 到行动：拿到问题之后该干什么
- 23.2 内部 Benchmark 的构建与维护
- 23.3 数据版本管理
- 23.4 数据飞轮：用模型的能力反哺数据生产
- 23.5 一个完整的迭代周期长什么样

第七部分 不只是写代码：算法工程师的职场生存

第二十四章 你的队友们：认识团队里的每个角色

- 24.1 谁是谁？算法工程师周围的角色地图
- 24.2 和产品经理打交道：先把需求边界说清楚
- 24.3 和测试工程师打交道：出了问题到底算谁的
- 24.4 和项目经理打交道：排期、资源协调与进度同步
- 24.5 互联网黑话生存指南

第二十五章 向上管理与资源争取

- 25.1 让 leader 知道你在干什么、干得怎么样
- 25.2 让 leader 给你资源：算力、人力、标注预算怎么申请

第二十六章 工作交接：屎山之间的传承

26.1 接手别人的工作

26.2 把你的工作交接给别人

第八部分 求职与破局：拿到属于你的那张船票

第二十七章 面试这件事

27.1 简历怎么写、往哪投

27.2 笔试与算法题

27.3 八股题：怎么准备才不是死背

27.4 项目经验题：怎么把你做过的事讲成一个好故事

第二十八章 反向背调：这个 offer 值不值得接

28.1 面试时怎么反向收集信息

28.2 拿到 offer 之后怎么做最终决策

28.3 离职与跳槽：既是终点，也是起点

第二十九章 终身学习与职业选择

29.1 入职前六个月：从新人到靠谱队友

29.2 怎么在这个领域持续跟上

29.3 那些私信里反复出现的问题

29.4 算法工程师的痛苦

后记