

这一路下来，你不仅拿到了那个极其好用的计算捷径 $Var(X) = E(X^2) - [E(X)]^2$ ，还摸清了方差的脾气：常数没有波动，整体平移不影响散布，而独立变量的叠加就像两个人各自手抖、互不干涉，波动只能纯粹相加。最硬核的还要数切比雪夫不等式，它连具体的分布形态都不挑，直接甩给你一个保底的概率边界。

现在，你手里捏着期望和标准差，看一个随机变量终于有了“圆心”和“散布半径”，总算是一张完整的数字画像了。

但这还不是终点。我们目前一直在跟单个变量死磕。可现实世界里，事情往往是扎堆连动的。比如身高和体重，比如气温和冷饮销量，它们俩放在一块儿，是不是有点同进同退的意思？要揪出两个变量之间是怎么“协同波动”的，光靠目前的工具就不顶用了。下一节的协方差就是干这个的。

AI 视野 · 百亿参数大模型的定海神针

在训练深层神经网络（如目前主流的 Transformer 架构）时，数据信号在一层层网络中穿梭，其波动的“幅度”极易失控——要么方差连乘爆炸导致数值溢出，要么方差不断缩水导致信号彻底消失。为了驾驭这种疯狂的波动，AI 研究者们引入了层归一化（Layer Normalization）技术。它的核心操作异常简单直接：将每一层产生的数据减去期望后，直接除以本节所学的标准差。这就好比用标准差作为一把硬性“标尺”，将所有即将暴走的数据强行按回统一的基准线上（强制方差为1）。没有这把标尺来稳住阵脚，今天任何深层 AI 模型都会在训练初期的剧烈震荡中崩溃。

5.3 协方差与相关系数：变量间的爱恨情仇

在上一章，我们为单个随机变量量身定制了“个人简历”——用期望描述其平均水准，用方差描述其波动大小。那么，当两个变量站在一起时，我们该如何描述它们之间的关系呢？它们会步调一致，还是背道而驰，抑或是各走各的路？

打个比方，就像很多人从大学起就养成的熬夜习惯。如果我们把“昨晚熬夜的程度”当成变量 X ，“今天白天的精神状态”当成变量 Y 。单独看，这两个变量都有自己的平均值和波动范围；但当它们放在一起时，这俩显然不是各走各的路—— X 飙高， Y 就得拉垮。它们之间这种“牵一发而动全身”的协同默契，就是我们要讲的协方差。

5.3.1 协方差：最初的“感觉”

怎么把这种“协同变化”的感觉翻译成数学公式？先拿生活里的现象找找灵感。

想象你每天记录两个变量：一个是当天的气温（相对于常年平均气温的偏离），另一个是冰激凌的销量（相对于平均销量的偏离）。你可能会观察到这样的模式：

- 在气温高于平均值的日子，冰激凌销量也往往高于平均值。
- 在气温低于平均值的日子，冰激凌销量也往往低于平均值。

换句话说，气温和冰激凌销量的“偏离”方向经常保持一致。我们想把这种“同向偏离”或“反向偏离”的模式数字化。

一个非常朴素的想法呼之欲出：把两个变量的偏离值相乘，然后看看这个乘积在长期表现中的平均趋势。

- 如果两个偏离通常同号（正正或负负），那么乘积为正，平均值也会是正的。

- 如果两个偏离通常异号（正负或负正），那么乘积为负，平均值也会是负的。
 - 如果两个偏离有时同号、有时异号，没有固定模式，那么乘积的正负抵消，平均值就会接近零。

定义：对于两个随机变量 X 和 Y ，它们的协方差定义为：

$$\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])]$$

它干了三件事：

- $X - E[X]$ 和 $Y - E[Y]$ ：算偏离。看看 X 和 Y 到底比自己的平均水平高还是低（可正可负）。
- $(X - E[X])(Y - E[Y])$ ：算乘积。这个乘积的符号，直接锁定了两个变量偏离方向的协同信息。
- $E[\cdot]$ ：算期望（长期平均）。我们对这个乘积取平均，从而捕捉稳定的协同模式。

为了让你更直观地感受，假设我们抽查了三天的观测数据。注意，为了方便看清本质，这些数据已经提前“中心化”了（即减去了自身的均值）：

天数	X 的偏离	Y 的偏离	乘积
1	+2	+1	+2
2	+1	+2	+2
3	-3	-3	+9
平均			$\frac{2+2+9}{3} = 4.33$

这三天的乘积都是正的，平均为正，表明 X 和 Y 存在“同向偏离”的默契。这就是正协方差。

再看另一种情况：

天数	X 的偏离	Y 的偏离	乘积
1	+2	-2	-4
2	+1	-1	-1
3	-3	+3	-9
平均			$\frac{-4-1-9}{3} = -4.67$

这三天的乘积都是负的，平均为负，表明 X 和 Y 经常“反向偏离”。这就是负协方差。

最后看一种情况：

天数	X 的偏离	Y 的偏离	乘积
1	+2	+1	+2
2	+1	-2	-2
3	-2	+1	-2
4	-1	0	0
平均			$\frac{2-2-2+0}{4} = -0.5$

这里的乘积有正有负，平均后接近零，表明它俩各玩各的，根本没有稳定的协同模式。

正如图 5.7 所示，协方差的符号确实能告诉我们两个变量协同变化的方向：

- **正值**：表明当 X 偏高时， Y 也倾向于偏高；当 X 偏低时， Y 也倾向于偏低。我们称之为“正相关”。

- **负值**：表明当 X 偏高时， Y 却倾向于偏低；当 X 偏低时， Y 却倾向于偏高。我们称之为“负相关”。

- **零值**：表明没有明显的线性协同趋势。注意，这里强调“线性”。协方差为零，我们称之为“不相关”，但这绝不意味着它们毫无关系。后面会细聊这个天坑。

不过，按这个定义硬算太折磨人了：得先求均值，再算偏差，最后还得求乘积的期望。有没有能“偷懒”的公式？

有的。利用期望运算的线性性质（这是我们老朋友了），我们可以推导出一个极其常用的计算式：

$$\begin{aligned}\text{Cov}(X, Y) &= E[(X - E[X])(Y - E[Y])] \\ &= E[XY - X \cdot E[Y] - E[X] \cdot Y + E[X]E[Y]] \\ &= E[XY] - E[X]E[Y] - E[X]E[Y] + E[X]E[Y] \\ &= E[XY] - E[X]E[Y]\end{aligned}$$

一下子清爽多了。协方差，就等于“乘积的期望”减去“期望的乘积”。这个公式不仅好算，还顺手帮我们建立了一个重要的逻辑链条：如果 X 和 Y 是独立的（此时 $E[XY] = E[X]E[Y]$ ），那么它们的协方差必然为零。请把这个链条死死记住：**独立 $\Rightarrow$ 不相关**。




图 5.7: 协方差的几何直觉：数据的分布形态决定了同向偏离（正相关）、反向偏离（负相关）和无序偏离（不相关）。虚线代表变量的均值。

我们来看个更贴地的例子。假设你观察到三个同学的数学学习时间和成绩有这样的关系：

- A同学：学习时间比全班平均多2小时，成绩比全班平均高10分。
- B同学：学习时间比全班平均少1小时，成绩比全班平均低5分。
- C同学：学习时间比全班平均多3小时，成绩比全班平均低2分。

如果班上像A、B这样的情况居多，那么“偏离乘积”的平均值（协方差）就是正的；如果像C这样的情况居多，协方差就是负的。如果各种神仙情况混杂，正负抵消，协方差就接近零了。

5.3.2 协方差与相关系数的运算性质

我们之所以要摸清这些性质，是因为协方差本质上是在算两个变量的“重合度”。懂了它的脾气，以后的复杂计算其实就像搭积木一样。先看最基本的几条规矩：

1. 协方差的基本运算性质

协方差具有以下重要性质（以下假设涉及的期望和方差都存在，且 a, b, c, d 为常数）：

- 对称性： $\text{Cov}(X, Y) = \text{Cov}(Y, X)$
- 与自身的关系： $\text{Cov}(X, X) = \text{Var}(X)$
- 线性性： $\text{Cov}(aX + b, cY + d) = ac \cdot \text{Cov}(X, Y)$
- 分配律： $\text{Cov}(X + Y, Z) = \text{Cov}(X, Z) + \text{Cov}(Y, Z)$
- 双线性：协方差对每个变量都是线性的：

$$\text{Cov}(aX + bY, Z) = a\text{Cov}(X, Z) + b\text{Cov}(Y, Z)$$

$$\text{Cov}(X, cY + dZ) = c\text{Cov}(X, Y) + d\text{Cov}(X, Z)$$

2. 方差的可加性与推广

借助协方差的分配律，我们可以推导出方差加法公式。

对于任意两个随机变量 X 和 Y ：

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$$

证明：

$$\begin{aligned} \text{Var}(X + Y) &= \text{Cov}(X + Y, X + Y) \\ &= \text{Cov}(X, X) + \text{Cov}(X, Y) + \text{Cov}(Y, X) + \text{Cov}(Y, Y) \\ &= \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y) \end{aligned}$$

这个公式如果推广到多个变量，形式也很整齐。对于三个随机变量 X, Y, Z ：

$$\begin{aligned} \text{Var}(X + Y + Z) &= \text{Var}(X) + \text{Var}(Y) + \text{Var}(Z) \\ &\quad + 2[\text{Cov}(X, Y) + \text{Cov}(X, Z) + \text{Cov}(Y, Z)] \end{aligned}$$

更一般地，对于 n 个随机变量 $X_1, X_2, \dots, X_n$ ：

$$\text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i) + 2 \sum_{1 \leq i < j \leq n} \text{Cov}(X_i, X_j)$$

例 5.18 已知随机变量 X 和 Y 的方差分别为 $\text{Var}(X) = 4$ ， $\text{Var}(Y) = 9$ ，协方差 $\text{Cov}(X, Y) = 3$ 。求：(1) $\text{Var}(2X - 3Y + 1)$ (2) $\text{Cov}(X + Y, X - Y)$

解答：

(1) 利用方差公式和协方差的线性性质：

$$\begin{aligned} \text{Var}(2X - 3Y + 1) &= \text{Var}(2X - 3Y) \quad (\text{常数加减不影响方差}) \\ &= \text{Var}(2X) + \text{Var}(-3Y) + 2\text{Cov}(2X, -3Y) \\ &= 4\text{Var}(X) + 9\text{Var}(Y) - 12\text{Cov}(X, Y) \\ &= 4 \times 4 + 9 \times 9 - 12 \times 3 \\ &= 16 + 81 - 36 = 61 \end{aligned}$$

(2) 利用协方差的分配律：

$$\begin{aligned}\text{Cov}(X + Y, X - Y) &= \text{Cov}(X, X) - \text{Cov}(X, Y) + \text{Cov}(Y, X) - \text{Cov}(Y, Y) \\ &= \text{Var}(X) - \text{Cov}(X, Y) + \text{Cov}(X, Y) - \text{Var}(Y) \\ &= \text{Var}(X) - \text{Var}(Y) = 4 - 9 = -5\end{aligned}$$

5.3.3 方差：特殊的协方差

在继续往下走之前，不妨开个脑洞：我们学过的方差，与协方差到底有什么关系？回忆方差的定义：

$$\text{Var}(X) = E[(X - E[X])^2]$$

再看看协方差的定义：

$$\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])]$$

如果你把协方差公式里的 Y 全部换成 X ，让变量跟自己去“相亲”，会得到什么？

$$\text{Cov}(X, X) = E[(X - E[X])(X - E[X])] = E[(X - E[X])^2] = \text{Var}(X)$$

方差就是自己与自己的协方差！ 这个极简的等式捅破了一层窗户纸：

- 方差衡量的是单个变量内部的“波动”。
- 协方差衡量的是两个变量之间的“协同波动”。
- 当两个变量是同一个东西时，它们的“协同波动”自然就退化成了自身的波动。

它的意义不止于此：

1. 那个常用的方差计算公式 $\text{Var}(X) = E[X^2] - (E[X])^2$ ，其实就是协方差计算公式 $\text{Cov}(X, Y) = E[XY] - E[X]E[Y]$ 在 $Y = X$ 时的特例而已。
2. 方差的所有性质，全部可以从协方差的性质里顺藤摸瓜推导出来。
3. 这为我们提供了一种统一视角：方差和协方差，本质上是同一个数学概念在不同情境下的表现。

5.3.4 协方差的“尺子问题”与标准化

协方差这把尺子哪都好，就是有个大毛病——它是个“势利眼”，特别容易被单位带偏。算出身高（米）和体重（千克）的协方差是 0.15，如果你非要把身高换成厘米去算，数值瞬间变成 15。难道换了个度量单位，关系凭空就变强了 100 倍？这显然扯淡。

问题的根源在于，协方差是有“量纲”的（继承了 X 和 Y 的物理单位），而且它的数值大小极度依赖于变量自身的波动幅度（方差）。一个“天生”波动剧烈的变量，它和其他变量的协方差很容易被拉得很大，但这未必代表它们关系就最紧密。

很多学生在实战中容易踩这个坑：算出一个数值很大的协方差，就兴奋地以为发现了什么惊天强关联。不，我们急需一把无视单位的“统一标尺”。

做法很简单：**标准化**。强行扒掉量纲的外衣，统一到相同的尺度上再比较。

于是，我们给协方差加上了一道工序，得到了大名鼎鼎的标准化版本——**相关系数**。

定义：随机变量 X 和 Y 的（皮尔逊）相关系数 ρ_{XY} 定义为：

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)}\sqrt{\text{Var}(Y)}} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

除以两个标准差的这个小动作，带来了几个关键的变化：

- **无量纲：**分子分母的单位完美抵消， ρ 变成了一个纯粹的、被死死锁在 -1 和 1 之间的数值。
- **标准化的强度：**现在，我们可以理直气壮地比较任意两对变量的线性关系强度了。 ρ 越接近 1 或 -1 ，线性关系越强；越接近 0 ，线性关系越弱。
- **方向的保留：** ρ 的符号与协方差完全一致，保留了“正相关”或“负相关”的方向信息。

这里藏着一个几何视角：这串代数公式的背后，其实是一幅清晰的几何画面。（以下推导涉及到样本均值和样本方差的内容，我们在统计学部分会详细介绍。如果你现在觉得陌生也没关系，只需领会背后的几何思想即可。在这里，我们暂且用样本均值代替期望，用样本方差代替理论方差。）

首先，考虑 X 和 Y 的 n 次独立观测样本 $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ 。我们可以将观测值序列 $(x_1, x_2, \dots, x_n)$ 和 $(y_1, y_2, \dots, y_n)$ 分别看作一个 n 维空间中的超长向量，记为 $\vec{x}$ 和 $\vec{y}$ 。

然而，相关系数公式里用的是 $X - E[X]$ 和 $Y - E[Y]$ 。这在几何上意味着我们需要对每个向量进行“中心化”：把每个分量都减去该向量的平均值，相当于把原点挪到了数据的重心。

$$\vec{x}_c = (x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_n - \bar{x})$$

$$\vec{y}_c = (y_1 - \bar{y}, y_2 - \bar{y}, \dots, y_n - \bar{y})$$

这里的 $\vec{x}_c$ 和 $\vec{y}_c$ 就是“中心化”后的向量。

接下来看协方差和方差怎么化身为向量运算。样本协方差为：

$$\text{Cov}_{\text{sample}}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

仔细看分子，这恰恰就是那两个中心化向量的点积（内积）：

$$\vec{x}_c \cdot \vec{y}_c = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}),$$

所以：

$$\text{Cov}_{\text{sample}} = \frac{\vec{x}_c \cdot \vec{y}_c}{n}$$

同样，样本方差为：

$$\text{Var}_{\text{sample}}(X) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

分子正是中心化向量 $\vec{x}_c$ 的长度的平方：

$$\|\vec{x}_c\|^2 = \sum_{i=1}^n (x_i - \bar{x})^2,$$

所以它的标准差就是：

$$\sigma_{X, \text{sample}} = \sqrt{\text{Var}_{\text{sample}}(X)} = \frac{1}{\sqrt{n}} \|\vec{x}_c\|$$

对 Y 同理, $\sigma_{Y,\text{sample}} = \frac{1}{\sqrt{n}} \|\vec{y}_c\|$ 。

把上面这些几何零件组装进相关系数的公式里:

$$\rho_{XY} = \frac{\text{Cov}_{\text{sample}}(X, Y)}{\sigma_{X,\text{sample}} \sigma_{Y,\text{sample}}} = \frac{\frac{1}{n} (\vec{x}_c \cdot \vec{y}_c)}{\left(\frac{1}{\sqrt{n}} \|\vec{x}_c\| \right) \left(\frac{1}{\sqrt{n}} \|\vec{y}_c\| \right)} = \frac{\vec{x}_c \cdot \vec{y}_c}{\|\vec{x}_c\| \|\vec{y}_c\|}$$

所有的 n 和 $\sqrt{n}$ 抵消了, 最终:

$$\rho_{XY} = \frac{\vec{x}_c \cdot \vec{y}_c}{\|\vec{x}_c\| \|\vec{y}_c\|}$$

这不就是线性代数里两个向量求夹角余弦值的标准定义吗? 如果记这两个向量的夹角为 θ , 那么:

$$\rho_{XY} = \cos \theta$$

结论呼之欲出: 相关系数 ρ_{XY} 的几何意义, 就是将两个变量的观测值中心化并视为高维向量后, 它们之间夹角的余弦值。

把数字变成夹角, 好处是什么? 统计数据一下子有了画面感:

- $\rho = 1$ 时, $\theta = 0^\circ$, 两个箭头完全重合, 存在严格的正比例线性关系。
- $\rho = -1$ 时, $\theta = 180^\circ$, 两个箭头背道而驰, 存在严格的负比例线性关系。
- $\rho = 0$ 时, $\theta = 90^\circ$, 两个箭头垂直 (正交), 这表示在线性层面上, 它们互不干涉。
- $|\rho|$ 越接近 1, 夹角越小, 意味着数据在多维空间中的指向越趋同, 线性关系越强。

这个视角 (见图 5.8) 将概率论与初等几何连接起来, 为我们提供了一个坚固的图像化框架。更重要的是, 它为我们打开了通往现代人工智能底层核心——余弦相似度——的大门。

为了加深印象, 我们拿个极端的例子验算一下。假设有四位同学的学习时间(X)和数学成绩(Y)如下:

- A同学: 学习时间 2 小时, 成绩 65 分。
- B同学: 学习时间 4 小时, 成绩 75 分。
- C同学: 学习时间 6 小时, 成绩 85 分。
- D同学: 学习时间 8 小时, 成绩 95 分。

经过简单计算可得: $E[X] = 5, E[Y] = 80, \text{Cov}(X, Y) = 25, \sigma_X \approx 2.236, \sigma_Y \approx 11.180$ 。于是:

$$\rho_{XY} = \frac{25}{2.236 \times 11.180} \approx 1.000$$

结果不多不少, 等于1。这说明这四个点在坐标图上严丝合缝地排在一条直线上。当然, 在现实世界中, 完美的线性关系 ($\rho = \pm 1$) 几乎不存在。你更常遇到的是像 0.82、-0.43 这样的数值, 它们指示着趋势的强弱, 但绝非精确的预测。

比如, 科学研究发现, 每日步数和睡眠质量之间的相关系数大约在 0.3 到 0.4 之间。这代表一种温和的正相关——走路多的人普遍睡得更好, 但也总有人暴走两万步依然失眠, 因为睡眠还受心情、饮食等无数因素的牵扯。

5.3.5 相关系数的性质与证明

既然把相关系数的底牌都掀开了, 接下来它的几条“硬核脾气”也就很好懂了。




图 5.8: 相关系数的几何视角: 将中心化后的数据点视为多维空间中的向量, 相关系数 ρ 恰好等于这两个向量夹角 θ 的余弦值。

性质1: 对称性

$$\rho_{XY} = \rho_{YX}$$

说明: 直接看定义, 分子分母全是对称的。

性质2: 与自身的关系

$$\rho_{XX} = 1$$

说明: 自己跟自己的夹角肯定是 0° , 余弦值当然是 1。代数上也能秒证:

$$\rho_{XX} = \frac{\text{Cov}(X, X)}{\sqrt{\text{Var}(X)}\sqrt{\text{Var}(X)}} = \frac{\text{Var}(X)}{\text{Var}(X)} = 1$$

性质3: 取值范围 (最重要!)

$$-1 \leq \rho_{XY} \leq 1$$

证明: 除了用“余弦值域”这个几何降维打击来理解, 严谨的概率论证明需要借用著名的柯西-施瓦茨不等式:

$$[E(UV)]^2 \leq E[U^2]E[V^2]$$

令 $U = X - E[X]$, $V = Y - E[Y]$, 则有:

$$[E(UV)]^2 = [\text{Cov}(X, Y)]^2$$

$$E[U^2] = \text{Var}(X)$$

$$E[V^2] = \text{Var}(Y)$$

代入不等式, 得到:

$$[\text{Cov}(X, Y)]^2 \leq \text{Var}(X)\text{Var}(Y)$$

两边开平方（注意取绝对值），再把方差除过去，就是：

$$|\rho_{XY}| = \left| \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)}\sqrt{\text{Var}(Y)}} \right| \leq 1$$

性质4：取等条件 $\rho_{XY} = 1$ 当且仅当存在常数 $a > 0, b$ 使得 $Y = aX + b$ （以概率1成立）。 $\rho_{XY} = -1$ 当且仅当存在常数 $a < 0, b$ 使得 $Y = aX + b$ （以概率1成立）。

性质5：线性变换下的表现 设 $U = aX + b, V = cY + d$ ，其中 $a, c \neq 0$ ，则有：

$$\rho_{UV} = \text{sign}(ac) \cdot \rho_{XY}$$

其中 $\text{sign}(ac)$ 是 ac 的符号（一正一负相乘得负号，同号相乘得正号）。

证明： 首先算出协方差：

$$\text{Cov}(U, V) = \text{Cov}(aX + b, cY + d) = ac \cdot \text{Cov}(X, Y)$$

然后是标准差（注意绝对值，标准差永远是正的）：

$$\sigma_U = |a|\sigma_X, \quad \sigma_V = |c|\sigma_Y$$

两边一除：

$$\rho_{UV} = \frac{\text{Cov}(U, V)}{\sigma_U \sigma_V} = \frac{ac \cdot \text{Cov}(X, Y)}{|a|\sigma_X \cdot |c|\sigma_Y} = \frac{ac}{|a||c|} \cdot \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} = \text{sign}(ac) \cdot \rho_{XY}$$

直观理解： 这条性质告诉你，相关系数对数据的平移和缩放具有“免疫力”。不管你是把米换成厘米，还是把摄氏度换成华氏度，只要是不改变数据内在形状的线性折腾，相关系数都稳如泰山（顶多因为乘了个负数而反转一下符号）。

性质6：与独立性的关系 如果 X 和 Y 独立，则 $\rho_{XY} = 0$ （但反之不成立！）。

证明： 独立意味着 $\text{Cov}(X, Y) = E[XY] - E[X]E[Y] = 0$ ，所以 $\rho_{XY} = 0$ 。

性质7：相关系数为0的条件 $\rho_{XY} = 0$ 当且仅当 $\text{Cov}(X, Y) = 0$ ，我们称 X 和 Y “不相关”。

重要应用： 还记得方差的加法公式吗？

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$$

一旦 $\rho_{XY} = 0$ （即不相关），后面的尾巴就归零了，公式变成：

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$$

所以，方差能直接相加的**真正条件**是：不相关即可，不必非得独立！

例 5.19 已知随机变量 X 和 Y 的相关系数为 ρ ，且方差分别为 σ_X^2 和 σ_Y^2 。求 $aX + bY$ 与 $cX + dY$ 的相关系数，其中 a, b, c, d 为非零常数。

解答： 令 $U = aX + bY, V = cX + dY$ 。

$$\begin{aligned} \text{Cov}(U, V) &= \text{Cov}(aX + bY, cX + dY) \\ &= ac\text{Cov}(X, X) + ad\text{Cov}(X, Y) + bc\text{Cov}(Y, X) + bd\text{Cov}(Y, Y) \\ &= ac\sigma_X^2 + (ad + bc)\text{Cov}(X, Y) + bd\sigma_Y^2 \\ &= ac\sigma_X^2 + (ad + bc)\rho\sigma_X\sigma_Y + bd\sigma_Y^2 \end{aligned}$$

$$\begin{aligned}\sigma_U^2 &= \text{Var}(aX + bY) = a^2\sigma_X^2 + 2ab\text{Cov}(X, Y) + b^2\sigma_Y^2 = a^2\sigma_X^2 + 2ab\rho\sigma_X\sigma_Y + b^2\sigma_Y^2 \\ \sigma_V^2 &= c^2\sigma_X^2 + 2cd\rho\sigma_X\sigma_Y + d^2\sigma_Y^2\end{aligned}$$

因此：

$$\rho_{UV} = \frac{ac\sigma_X^2 + (ad + bc)\rho\sigma_X\sigma_Y + bd\sigma_Y^2}{\sqrt{(a^2\sigma_X^2 + 2ab\rho\sigma_X\sigma_Y + b^2\sigma_Y^2)(c^2\sigma_X^2 + 2cd\rho\sigma_X\sigma_Y + d^2\sigma_Y^2)}}$$

这个看似头皮发麻的式子告诉我们：哪怕只是做个简单的线性组合，新变量间的相关性也可能变得极其复杂。但如果已知 X 和 Y 压根不相关 ($\rho = 0$)，公式瞬间就成了纸老虎：

$$\rho_{UV} = \frac{ac\sigma_X^2 + bd\sigma_Y^2}{\sqrt{(a^2\sigma_X^2 + b^2\sigma_Y^2)(c^2\sigma_X^2 + d^2\sigma_Y^2)}}$$

下面再看几道实战例题：

例 5.20 （相关系数的不变性）已知随机变量 X 和 Y 的相关系数 $\rho = 0.6$ 。定义新的变量：

$$U = 3X + 2, \quad V = -2Y + 1$$

求 U 和 V 的相关系数。

解答：观察发现， U 是 X 的线性变换（乘 3 加 2）， V 是 Y 的线性变换（乘 -2 加 1）。根据性质 5，相关系数只需要考虑系数乘积的符号。 $\text{sign}(3 \times (-2)) = -1$ 。所以：

$$\rho_{UV} = (-1) \times 0.6 = -0.6$$

例 5.21 （投资组合中的相关性）假设你有两种投资选择：

- 股票 A：期望收益率 8%，标准差 10%。
- 股票 B：期望收益率 12%，标准差 15%。

已知 A 和 B 的相关系数是 -0.3 。你决定将资金的 60% 投 A ，40% 投 B 。那么这个投资组合的期望收益率和标准差是多少？

解答：首先，组合收益率 $R_p = 0.6R_A + 0.4R_B$ 。期望收益率永远是线性的：

$$E[R_p] = 0.6 \times 8\% + 0.4 \times 12\% = 4.8\% + 4.8\% = 9.6\%$$

但方差（风险）的计算就必须考虑它们之间的相关系数了：

$$\begin{aligned}\text{Var}(R_p) &= (0.6)^2\text{Var}(R_A) + (0.4)^2\text{Var}(R_B) + 2 \times 0.6 \times 0.4 \times \text{Cov}(R_A, R_B) \\ &= 0.36 \times (0.1)^2 + 0.16 \times (0.15)^2 + 0.48 \times \rho \times \sigma_A \times \sigma_B \\ &= 0.36 \times 0.01 + 0.16 \times 0.0225 + 0.48 \times (-0.3) \times 0.1 \times 0.15 \\ &= 0.0036 + 0.0036 - 0.00216 \\ &= 0.00504\end{aligned}$$

所以标准差为 $\sqrt{0.00504} \approx 0.071$ ，即 7.1%。

关键洞见：单独买 A 的风险是 10%，单独买 B 的风险是 15%，但把它们组合起来买，风险降到了 7.1%！这就是金融界老生常谈的**分散化投资**的数学真相：只要资产之间不是穿一条裤子的完全正相关（本题甚至是互补的负相关），组合投资的风险就能被对冲掉。

例 5.22（相关系数的界限）已知随机变量 X 和 Y 的方差分别为 4 和 9。证明它们的协方差绝对值不超过 6。

解答：根据相关系数永远在 $[-1, 1]$ 之间的铁律，我们有：

$$|\rho| = \frac{|\text{Cov}(X, Y)|}{\sqrt{4} \times \sqrt{9}} = \frac{|\text{Cov}(X, Y)|}{2 \times 3} = \frac{|\text{Cov}(X, Y)|}{6} \leq 1$$

把分母挪过去，马上得到 $|\text{Cov}(X, Y)| \leq 6$ 。

5.3.6 不相关条件的意义：一个重要补丁

学到这里，我们需要给前面学过的知识打个补丁。在前面的章节里，为了降低大家的认知负荷，我们曾简单地说过一个结论：只有当 X 和 Y 独立时，才有 $E[XY] = E[X]E[Y]$ ，方差才能直接相加（ $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$ ）。

现在你的功力已经到了，我们需要把这个条件松一松绑。

回顾一下协方差的等价公式：

$$\text{Cov}(X, Y) = E[XY] - E[X]E[Y]$$

一旦 $\text{Cov}(X, Y) = 0$ （即 X 和 Y 不相关），上面的公式立马变成：

$$E[XY] = E[X]E[Y]$$

这意味着，只要 X 和 Y 不相关，乘积的期望就等于期望的乘积。

同理，对于方差的加法：

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$$

只要不相关，尾巴就消失，于是：

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$$

方差可加的底线也是“不相关”。

独立当然能推出不相关（所以独立时这些等式肯定成立），但独立是一个极其苛刻的条件（要求两个变量彻底互不干涉）。在实际的工程或统计计算里，我们往往只需要去验证它们是否“不相关”即可，这能为你省下大量的证明精力。

举个例子，假设已知 X 和 Y 不相关，且 $E[X] = 2$, $E[Y] = 3$, $\text{Var}(X) = 4$, $\text{Var}(Y) = 9$ 。我们不用管它俩是否绝对独立，就能直接断言：

- $E[XY] = 2 \times 3 = 6$
- $\text{Var}(X + Y) = 4 + 9 = 13$

但是，千万别走极端：在需要更深层概率运算的时候（比如计算联合概率 $P(X \leq x, Y \leq y) = P(X \leq x)P(Y \leq y)$ ），独立这个强条件依然是不可替代的。不相关只管线性，不管其他。

5.3.7 常见误区扫雷

误区1：“相关系数大，就意味着因果关系强” 这是初入数据分析行业最容易犯的低级错误。相关系数只负责告诉你它俩有没有伴随变化，绝不证明谁导致了谁。最经典的笑话是：数据显示，夏天冰淇淋的销量和河里的溺水人数呈现高度正相关。难道

是为了救人要去查封冰淇淋厂？真正的共同幕后黑手是“天气热”：天热让更多人吃冰淇淋，也让更多人下河游泳。

误区2：“相关系数为0.8的关系，是0.4的两倍强” 别想当然！相关系数这把尺子的刻度不是均匀的。实际上，把相关系数平方一下（统计学里叫决定系数 R^2 ），才能准确反映关系强度。 $0.8^2 = 0.64$ ，说明 X 的波动能解释 64% 的 Y 的波动；而 $0.4^2 = 0.16$ ，只能解释 16%。这么一算，0.8 的说服力可是 0.4 的 4 倍！

误区3：“算出相关系数，我就能拍板定论了” 只要是负责任的分析师，绝不会只看一个孤零零的 ρ 值。你还得：

1. 画个散点图看看（万一是一个极其离谱的异常数据点，把整个系数拉高了呢？）。
2. 确认它俩是不是在走曲线（因为雷达只扫直线）。
3. 多问一句：是不是存在第三个幽灵变量在同时操控它们？

误区4：“正相关是好事，负相关是坏事” 这就得看具体情况了。就像刚刚的例题，在投资组合里，资产组合的负相关反而是保护你本金的安全气囊。而在吃药治病时，药量与疗效的正相关是救命的，但与副作用的负相关（药量越大副作用越小，虽然很少见）更是极品好药。数学工具本身是没有道德立场的。

5.3.8 Python实验室

打开配套资源包中的 `correlation_blind_spot.py`，跑一下。这段脚本构建了一个“非线性陷阱”：数据呈现出 100% 确定的抛物线规律，皮尔逊相关系数却给出一个 0 值——“线性雷达”彻底失明。你还可以在代码的配置区把函数改成正弦波或绝对值，看看这个盲区的边界在哪。

5.3.9 总结

这一节主要学习了两个变量之间的“协同关系”。一开始我们搞出了协方差，用来量化这俩变量是不是同进同退。但协方差太依赖度量单位，稍微换个尺度数值就乱飘。为了扒掉这层干扰，我们弄出了相关系数 ρ 。这玩意自带一个物理外挂——把它看成空间里两个中心化向量的夹角余弦，直线的亲密度一眼就能看透。

顺着这条线，我们也顺手拆了一个最坑人的幻觉：“不相关”绝对不等于“独立”。相关系数 ρ 只是一部探测线性关系的单频雷达。如果是像 $Y = X^2$ 这种铁板钉钉的非线性关系，哪怕它俩绑得再死，这部雷达也是全盲的。**记住了，独立必然导致不相关，但不相关仅仅说明它们没走在同一条直线上而已。**

拿着相关系数这副专门看线性关系的滤镜，你已经能看清很多数据表象了。但它绝不能告诉你背后的“为什么”。就像顺丰快递的配送速度和客户好评率可能高度正相关，但单凭一个 ρ 值，你没法证明是速度快直接带来了好评，还是网点管理水平高同时导致了这两者。在现实中，千万别拿着相关当因果。

接下来，顺着这个逻辑，我们要去会一会数据世界里最容易让人翻车的话题——相关性与因果性。至于要是变量不再是两个，而是变成了你在大模型里遇到的成千上万个特征向量时该怎么算，那就得请出协方差矩阵了，我们放到多维变量那一章再去细盘。

AI 视野 · 现代大模型的语义量角器

在当今的大语言模型（LLM）和视觉语言模型（VLM）中，有一个极其核心的概念叫做“向量嵌入”（Embedding）。无论是你输入的一段提示词，还是上传的一张图片，都会被模型转换成包含几千个数字的高维向量。当 AI 需要在海量知识库中为你精准检索答案，或者进行图文匹配时，它底层的核心动作，正是快速计算你的查询向量与数据向量之间的余弦相似度。夹角越小，AI 就认为它们在语义上越“相关”。你本节掌握的这个几何视角，直接构成了现代大模型理解世界相似性的数学基石。

5.4 扩展：余弦相似度与大模型的底层逻辑

在当今最火热的人工智能领域，无论是你常用的 DeepSeek、ChatGPT，还是那些能看图说话的多模态视觉语言模型（VLM），它们每天都在处理海量的文本和图像。机器不懂人类的语言，更不懂风花雪月，它们只能把万事万物都转化为高维空间里的一串数字。我们称之为“向量”。

这时候，怎么衡量两段文本的语义是否相近？怎么判断一张图片和一句话是否匹配？答案是大模型时代最基本的数学工具——余弦相似度。

5.4.1 从相关系数到“余弦相似度”

我们在上文已经对相关系数和余弦相似度的关系做了简单的介绍。我们用具体的例子来看看它们到底是怎么分道扬镳的。

首先回顾一个核心结论：我们说相关系数是两个“中心化”向量夹角的余弦。如果我们不做中心化，直接看原始数据拼成的向量呢？得到的就是“余弦相似度”。

为什么要抛弃“中心化”？在很多真实的业务场景里，数据的绝对数值本身就带有强烈的物理意义或者语义特征。比如，在一张黑白照片里，像素值为 0 代表纯黑，255 代表纯白；在文本分析里，某个词出现的次数是 0 次还是 5 次，这是非常关键的频次信息。如果我们像计算相关系数那样，强行把所有像素或者词频都减去一个平均值，这就好比把所有大楼都连根拔起、统一挪到同一个起跑线上——相对高矮没变，但每栋楼原来站在哪里的信息就丢了。

这时候，我们不再关心它们各自围绕平均值是怎么波动的，我们只关心：这两个原始的箭头，在空间中是不是指向同一个大方向。

定义：对于两个非零向量 $\vec{u}$ 和 $\vec{v}$ ，它们的余弦相似度定义为它们夹角的余弦值：

$$\text{余弦相似度}(\vec{u}, \vec{v}) = \frac{\vec{u} \cdot \vec{v}}{\|\vec{u}\| \|\vec{v}\|} = \cos \phi$$

其中 $\vec{u} \cdot \vec{v}$ 是向量的内积， $\|\vec{u}\|$ 和 $\|\vec{v}\|$ 分别是向量的模长， ϕ 是两个向量的夹角。

作为对比，我们再把相关系数的公式摆在旁边：

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} = \frac{E[(X - \mu_X)(Y - \mu_Y)]}{\sqrt{E[(X - \mu_X)^2]} \sqrt{E[(Y - \mu_Y)^2]}}$$

如果将 X 和 Y 的观测值看作向量，那么相关系数就是先将每个向量减去其均值（中心化），再计算这两个新向量的余弦相似度。所以，相关系数可以看作是一种“先中心化，再计算余弦相似度”的特殊操作。